Proyecto Integrado: Transformación, Enriquecimiento de Datos y Respuestas a Preguntas de Negocio en E-commerce

María José Causil Silva

Santiago López Figueroa

Esteban Urrutia Bermudez

Institución Universitaria Digital de Antioquia

PREICA2602B020038: Proyecto Analítica Integrado 3

Andres Felipe Callejas

8 de noviembre de 2026

Contenido

1. Retoma de Necesidades, Preguntas de Negocio y Alcance 4

1.1 Planteamiento de la Necesidad y Beneficiarios 4

1.2 Relación de Preguntas de Negocio, Variables y Resultados Esperados .. **¡Error! Marcador no definido.**

1.3 Declaración de Limitaciones de Datos y Ajuste Metodológico..... 5

2. Metodología: Transformación y Validación de Calidad de Datos..... 5

2.1 Auditoría de Integridad, Nulos y Duplicados 6

2.2 Casting y Normalización de Formatos..... 6

3. Enriquecimiento de la Información y Diccionario de Datos Actualizado 6

3.1 Variables Derivadas y Justificación Operativa 6

3.2 Diccionario Actualizado de Variables Incorporadas 7

4. Resultados y Discusión de las Preguntas de Negocio..... 8

4.1 Respuesta a la Pregunta 1: Rentabilidad por Categoría y Desempeño por Canales 8

4.2 Respuesta a la Pregunta 2: Segmentos de Clientes y Análisis de Pareto (80/20) 9

4.3 Respuesta a la Pregunta 3: Ticket Promedio (AOV) por Segmento y Dispositivo 10

4.4 Evidencias Exportadas: Dataset Preparado y Reporte Triple A 11

5. Conclusiones del Avance y Aspectos por Resolver..... 12

Aspectos que Quedan sin Resolver y Próximos Pasos 13

6. Referencias..... 13

Índice de Tablas

Tabla 1. Relación entre preguntas de negocio, variables necesarias y resultados esperados — página 5

Tabla 2. Control de calidad y auditoría del DataFrame antes y después de la preparación — página 6

Tabla 3. Diccionario actualizado de variables incorporadas en el enriquecimiento — página 8

Tabla 4. Distribución de pedidos, unidades e ingresos totales por categoría de producto — página 9

Tabla 5. Rendimiento comercial y facturación bruta por canal de adquisición — página 9

Tabla 6. Comportamiento transaccional y aporte monetario por segmento de cliente — página 10

Tabla 7. Matriz de Ticket Promedio (AOV en USD) según segmento de cliente y dispositivo tecnológico — página 11

Proyecto Integrado: Transformación, Enriquecimiento de Datos y Respuestas a Preguntas de Negocio en E-commerce

Retoma de Necesidades, Preguntas de Negocio y Alcance

Planteamiento de la Necesidad y Beneficiarios

Conjunto de datos: Millat (s. f.), e-commerce-orders.

El sector del comercio electrónico contemporáneo exige una evaluación empírica y permanente de las transacciones históricas para garantizar la sostenibilidad operativa y la maximización del retorno sobre la inversión (ROI). La tienda en línea analizada registra un flujo sostenido de tráfico transaccional; sin embargo, tanto el valor promedio de cada pedido (AOV - Average Order Value) como las tasas de retención y recompra de clientes no exhiben el crecimiento proyectado por la dirección comercial.

La gerencia de e-commerce y los analistas de marketing sospechan que los recursos presupuestales de adquisición se están dispersando en canales de difusión que no capturan clientes de alto valor vital (LTV), y que las promociones vigentes no potencian las líneas de catálogo más rentables. Este proyecto descriptivo aborda dicha necesidad dotando a los líderes de marketing y estrategas comerciales de una base sustentada en datos para orientar la segmentación, la pauta y la gestión logística.

Relación de Preguntas de Negocio, Variables y Resultados Esperados

Al inicio del entorno analítico de trabajo (Jupyter Notebook), se carga el archivo original 'e-commerce-orders.csv' en una variable denominada df_raw, la cual se mantiene estrictamente inalterada en memoria para salvaguardar la reproducibilidad científica y servir como testigo de auditoría. A partir de una copia explícita de trabajo (df), se articulan las tres preguntas que guían

la investigación, detalladas en la Tabla 1 junto con sus variables requeridas y resultados esperados:

Tabla 1

Relación entre preguntas de negocio, variables necesarias y resultados esperados

Pregunta de Negocio	Variables Necesarias	Operación Analítica	Resultado Esperado
Pregunta 1: ¿Cuáles son las categorías más rentables y qué canales generan mayor volumen e ingresos?	category, channel, price, quantity, order_id	Agrupación bivariada sumando el producto price * quantity y conteo de órdenes.	Ranking de ingresos brutos y participación porcentual por categoría y canal publicitario.
Pregunta 2: ¿Qué segmentos de clientes aportan mayor facturación y cómo se comportan frente a Pareto?	customer_segment, customer_id, order_id, price, quantity	Agregación por segmento y curva de concentración acumulada por cliente único.	Distribución de volumen por lealtad (New, Returning, VIP) y verificación del principio 80/20.
Pregunta 3: ¿Cuáles son los patrones de ticket promedio (AOV) por segmento y tipo de dispositivo?	customer_segment, device_type, price, quantity	Tabla de contingencia bidimensional calculando la media ponderada de ventas.	Matriz de AOV (USD) para identificar brechas de conversión tecnológica por plataforma.

Nota. Marco operativo acordado para guiar la etapa de análisis descriptivo en Python.

Declaración de Limitaciones de Datos y Ajuste Metodológico

Es relevante declarar una limitación inherente al conjunto de datos provisto: la tabla histórica registra el precio de venta unitario ('price') y el volumen físico comprado ('quantity'), pero no incluye el costo de los bienes vendidos (COGS - Cost of Goods Sold), descuentos promocionales aplicados ni los costos de flete por despacho. Por consiguiente, el concepto de 'rentabilidad' se operacionaliza en esta investigación rigurosamente como ingreso bruto facturado (Gross Revenue / Total Sales). Se ajusta el alcance aclarando que los análisis describen volumen y facturación comercial, imposibilitando la determinación de márgenes netos de ganancia contable.

Metodología: Transformación y Validación de Calidad de Datos

Auditoría de Integridad, Nulos y Duplicados

El procesamiento técnico se implementó mediante scripts de Python estructurados en Jupyter Notebook. Previo a efectuar cualquier manipulación analítica, se auditó exhaustivamente la calidad del archivo crudo. La ejecución de df.duplicated().sum() reveló exactamente cero registros duplicados en sus 10.000 observaciones. Asimismo, la evaluación de completitud con df.isnull().sum() demostró la presencia del 100% de los datos en las 15 variables primarias.

Siguiendo los criterios de rigor metodológico, no se eliminó ninguna fila ni se realizaron imputaciones sintéticas de datos faltantes, preservando intacto el universo completo de transacciones (10.000 registros).

Casting y Normalización de Formatos

En la base original, las fechas de compra ('order_date') y despacho ('shipping_date') se encontraban tipadas como texto ('object'). Mediante la función pd.to_datetime(..., errors='coerce'), ambas columnas se transformaron al formato datetime64[ns], habilitando la computación precisa de diferencias cronológicas y estacionalidad. Adicionalmente, las variables cuantitativas 'price' y 'quantity' fueron aseguradas mediante pd.to_numeric(), garantizando la correcta ejecución de cálculos flotantes y enteros.

Tabla 2

Control de calidad y auditoría del DataFrame antes y después de la preparación

Dimensión de Calidad	Estado Inicial (Raw)	Estado Preparado	Impacto Metodológico
Cantidad de Filas	10,000	10,000	0 registros eliminados (100% retención).
Cantidad de Columnas	15	23	+8 variables analíticas derivadas.
Valores Faltantes (Nulos)	0 (0.00%)	0 (0.00%)	Completitud absoluta sin imputación.

Registros Duplicados	0	0	Unicidad transaccional verificada.
Formato de Fechas	object (string)	datetime64[ns]	Habilitación de análisis temporal y logístico.

Nota. Resultados comprobados mediante aserciones de código en Python previo al análisis.

Enriquecimiento de la Información y Diccionario de Datos Actualizado

Variables Derivadas y Justificación Operativa

El enriquecimiento de datos consistió en derivar variables operativas, temporales y de comportamiento directamente de las columnas base, evitando recurrir a fuentes externas que pudieran multiplicar registros o generar discrepancias de integración. Las métricas incorporadas responden a las necesidades del proyecto de la siguiente forma:

a) Valor monetario de la orden (total_revenue): Resulta de multiplicar de manera vectorizada el precio unitario por la cantidad adquirida (price * quantity), redondeado a dos cifras decimales. Es el insumo cuantitativo continuo para calcular el ticket promedio (AOV).

b) Tiempos y alertas logísticas (shipping_days y delivery_delay): Calculada como la diferencia en segundos convertida a días exactos entre la fecha de envío y la de compra. Aquellas órdenes con más de 3 días de procesamiento son señaladas con una bandera booleana para auditoría de servicio.

c) Frecuencia y fidelidad del usuario (customer_order_count y customer_recurrente): Identifica cuántos pedidos acumula cada cliente único y clasifica con un valor booleano si se trata de un comprador recurrente (más de una transacción en la plataforma).

d) Descomposición cronológica (order_year_month, order_month y order_day_name): Facilita el análisis de estacionalidad mensual y patrones semanales de tráfico comercial.

Diccionario Actualizado de Variables Incorporadas

Tabla 3

Diccionario actualizado de variables incorporadas en el enriquecimiento

Variable Incorporada	Tipo de Dato	Fórmula / Regla de Cálculo	Significado y Utilidad
total_revenue	float64	round(price * quantity, 2)	Ingreso bruto facturado por pedido (base para el cálculo del AOV).
shipping_days	float64	(shipping_date - order_date).total_seconds / 86400	Tiempo de procesamiento logístico en días continuos.
delivery_delay	bool	shipping_days > 3.0	Alerta booleana de demora en despacho en bodega.
customer_order_count	int64	groupby('customer_id')['order_id'].nunique	Historial acumulado de compras únicas del cliente.
customer_recurrente	bool	customer_order_count > 1	Identificador de comprador recurrente vs. comprador único.
order_year_month	string	order_date.dt.to_period('M')	Periodo contable mensual (AAAA-MM) para seguimiento temporal.
order_month	string	order_date.dt.month_name()	Nombre del mes de compra para estacionalidad de la demanda.
order_day_name	string	order_date.dt.day_name()	Día semanal de compra para caracterización del tráfico.

Nota. Elaboración propia. Variables calculadas en pandas sin recurrir a bases externas.

Resultados y Discusión de las Preguntas de Negocio

Con el DataFrame debidamente transformado y enriquecido, se ejecutaron las agrupaciones y comparaciones estadísticas para dar respuesta cuantitativa a las tres interrogantes de negocio. Los resultados reflejan la totalidad de las 10.000 órdenes evaluadas, con un volumen de facturación global de $5,334,932.86 USD.

Respuesta a la Pregunta 1: Rentabilidad por Categoría y Desempeño por Canales

Para identificar las categorías líderes y la efectividad de las rutas de adquisición, se totalizaron los pedidos, unidades despachadas e ingresos acumulados, calculando el ticket promedio de compra por grupo:

Tabla 4

Distribución de pedidos, unidades e ingresos totales por categoría de producto

Categoría	Pedidos	Unidades	Ingresos (USD)	Ticket Promedio	% Part.
Home	1,713	3,696	$921,394.85	$537.88	17.27%
Electronics	1,694	3,586	$910,153.11	$537.28	17.06%
Beauty	1,682	3,617	$888,823.19	$528.43	16.66%
Toys	1,666	3,552	$888,447.70	$533.28	16.65%
Clothing	1,620	3,392	$863,629.45	$533.10	16.19%
Books	1,625	3,404	$862,484.56	$530.76	16.17%

Nota. Exportado automáticamente como tabla_q1_categoria.csv. Total global facturado: $5,334,932.86 USD.

Tabla 5

Rendimiento comercial y facturación bruta por canal de adquisición

Canal	Pedidos	Clientes	Ingresos (USD)	Ticket Promedio	% Part.
Social	2,566	1,602	$1,358,397.30	$529.38	25.46%
Paid Search	2,525	1,586	$1,357,065.26	$537.45	25.44%
Email	2,474	1,559	$1,349,734.63	$545.57	25.30%
Organic	2,435	1,563	$1,269,735.67	$521.45	23.80%

Nota. Exportado automáticamente como tabla_q1_canal.csv. Suma exacta de órdenes: 10,000 transacciones.

Interpretación de hallazgos (P1): Las categorías 'Home' ($921,394.85 USD, 17.27%) y 'Electronics' ($910,153.11 USD, 17.06%) lideran la captación de ingresos brutos, impulsadas por un mayor volumen de artículos despachados y un precio medio unitario más alto. No obstante, la cartera de categorías exhibe una estabilidad notable, fluctuando todas entre el 16.17% y el 17.27%. En canales de adquisición, Social Media y Paid Search generan un virtual empate en el liderato (~25.45% cada una); sin embargo, Email Marketing registra el ticket promedio individual más alto de la tienda ($545.57 USD), posicionándolo como el canal de mayor calidad

transaccional. Por su parte, el canal Organic aporta un saludable 23.80%, demostrando un flujo natural relevante que disminuye la dependencia exclusiva de pauta paga.

Respuesta a la Pregunta 2: Segmentos de Clientes y Análisis de Pareto (80/20)

Para verificar el comportamiento transaccional según la lealtad y contrastar la concentración económica con el principio de Pareto, se agregaron las transacciones por segmento predeterminado (VIP, Returning, New) y se calculó la curva de concentración acumulada a nivel de clientes individuales:

Tabla 6

Comportamiento transaccional y aporte monetario por segmento de cliente

Segmento	Pedidos	Clientes	Ingresos (USD)	AOV (USD)	% Pedidos	% Ingresos
VIP	5,149	614	$2,722,687.10	$528.78	51.49%	51.04%
Returning	4,285	1,533	$2,316,406.64	$540.58	42.85%	43.42%
New	566	566	$295,839.12	$522.68	5.66%	5.55%

Nota. Exportado automáticamente como tabla_q2_segmentos_cliente.csv. Base total de clientes únicos: 2,713 usuarios.

Interpretación de hallazgos (P2): La segmentación constata una asimetría estructural de retención. Los clientes VIP concentran el 51.04% de las ventas globales ($2,722,687.10 USD) y el 51.49% de las órdenes, a pesar de estar conformados por únicamente 614 compradores únicos (un promedio extraordinario de 8.39 pedidos por cliente durante el año). Por su parte, los clientes 'Returning' representan el 43.42% de la facturación y exhiben el valor promedio de orden más elevado ($540.58 USD). En conjunto, ambos grupos recurrentes generan el 94.46% de las ventas totales de la plataforma.

En contraste, los compradores de una sola vez ('New', 566 clientes con exactamente un pedido cada uno) solo aportan el 5.55% de la facturación. Al contrastar con la regla clásica de Pareto (80/20) calculada acumulando el gasto de los 2.713 clientes únicos ordenados

descendentemente, se constató que el percentil 20% superior de clientes aporta el 51.84% de las ventas totales, requiriéndose del 46.2% de los clientes para alcanzar el 80% del ingreso acumulado. Este hallazgo demuestra que, si bien la empresa no cumple la polarización extrema del 80/20, sí presenta una dependencia crítica de un grupo nuclear VIP.

Respuesta a la Pregunta 3: Ticket Promedio (AOV) por Segmento y Dispositivo

Para resolver la interrogante tecnológica y comercial, se construyó una tabla de contingencia bidimensional cruzando los tres segmentos con las tres plataformas de compra registradas (Desktop, Mobile, Tablet):

Tabla 7

Matriz de Ticket Promedio (AOV en USD) según segmento de cliente y dispositivo tecnológico

Segmento de Cliente	Desktop (USD)	Mobile (USD)	Tablet (USD)	AOV Consolidado
New	$553.20	$571.00	$445.34	$522.68
Returning	$557.03	$529.66	$533.64	$540.58
VIP	$523.26	$527.50	$535.50	$528.78
Promedio General Dispositivo	**$539.43**	**$530.86**	**$529.49**	**$533.49**

Nota. Exportado automáticamente como tabla_q3_aov_segmento_dispositivo.csv. Media ponderada del ticket en dólares.

Interpretación de hallazgos (P3): El tráfico transaccional se distribuye casi equitativamente entre las tres plataformas: Desktop con 3,383 pedidos (33.83%), Tablet con 3,339 pedidos (33.39%) y Mobile con 3,278 pedidos (32.78%). En términos de valor monetario, Desktop sostiene el ticket promedio global más alto ($539.43 USD), explicado primordialmente por las compras efectuadas por clientes 'Returning' ($557.03 USD). Resulta sumamente revelador observar que en los usuarios nuevos ('New'), los teléfonos inteligentes alcanzan el ticket promedio más alto de toda la muestra ($571.00 USD), mientras que su interacción vía Tablet desciende drásticamente a $445.34 USD. Esto sugiere que las campañas orientadas a

captar nuevos clientes tienen un impacto de conversión de alto valor en smartphones, pero requieren optimización urgente de experiencia de usuario y pasarela de pago en tabletas.

Evidencias Exportadas: Dataset Preparado y Reporte Triple A

En concordancia con los lineamientos de la entrega, el entorno de código ejecutó la exportación automatizada de los siguientes artefactos en el directorio raíz del proyecto:

1. dataset_preparado_ecommerce.csv: Archivo integral con las 10.000 observaciones y las 23 columnas resultantes (originales y derivadas), listo para ingesta en herramientas de visualización (Power BI, Tableau o bibliotecas gráficas de Python).

2. Archivos tabulares de resultados: 'tabla_q1_categoria.csv', 'tabla_q1_canal.csv', 'tabla_q1_cruce_categoria_canal.csv', 'tabla_q2_segmentos_cliente.csv', 'tabla_q3_aov_segmento_dispositivo.csv' y 'tabla_q3_pedidos_segmento_dispositivo.csv'.

3. resumen_descriptivo_triple_a.txt: Documento de texto plano estructurado según la metodología Triple A (Auditoría, Analítica y Agregación), detallando dimensiones, completitud, conteo de nulos, estadísticas descriptivas (media, desviación, mínimos, percentiles y máximos) e indicadores clave de negocio (facturación total de $5,334,932.86 USD, AOV global de $533.49 USD, tasa de retrasos logísticos del 57.28% y porcentaje de transacciones recurrentes del 94.34%). Este archivo se sobreescribe y valida en cada corrida del pipeline.

Conclusiones del Avance y Aspectos por Resolver

El presente avance analítico permite formular conclusiones estratégicas respecto a la necesidad inicial de la organización:

1. Diversificación y Eficiencia en Canales: Las categorías 'Home' y 'Electronics' concentran la mayor facturación bruta. No obstante, el catálogo evidencia una sana diversificación de ingresos donde ninguna línea supera el 17.3% del total. En adquisición

publicitaria, las redes sociales (Social) y las búsquedas pagas (Paid Search) atraen el mayor volumen de compras, pero Email Marketing demuestra ser el canal más rentable por orden promedio ($545.57 USD), lo que justifica priorizar flujos automatizados de retención por correo.

2. Alta Concentración en el Núcleo VIP: El negocio descansa de forma casi absoluta sobre sus 614 clientes VIP y 1,533 clientes recurrentes, quienes explican el 94.46% de las ventas anuales. Con únicamente 566 clientes nuevos en el periodo (5.55% del ingreso), la mayor fuga de oportunidad radica en la falta de conversión del comprador primerizo hacia compras subsecuentes, demandando estrategias de onboarding y cupones de segundo pedido.

3. Disparidad Tecnológica en Checkout: Aunque el tráfico transaccional está repartido en partes iguales entre Desktop, Mobile y Tablet (~33% cada uno), el ticket promedio de usuarios nuevos en Tablet cae un 22% frente a Mobile ($445.34 vs. $571.00 USD), sugiriendo problemas de rendimiento en la interfaz táctil de pantalla mediana.

Aspectos que Quedan sin Resolver y Próximos Pasos

En virtud del alcance descriptivo inicial y las características de los datos, permanecen sin resolver los siguientes aspectos que deberán ser abordados en las etapas siguientes: (a) el cálculo del margen neto contable por línea de producto al no disponer de costos unitarios de compra (COGS) ni tarifas de flete; (b) la modelización predictiva de abandono (churn) para predecir cuándo un cliente VIP o recurrente dejará de comprar; y (c) la atribución multitoque para evaluar la interacción cruzada entre Social Media y Paid Search en una misma decisión de compra.

Referencias

Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2014). Metodología de la investigación (6.ª ed.). McGraw-Hill Education.

Millat. (s. f.). e-commerce-orders [Conjunto de datos]. Hugging Face. https://huggingface.co/datasets/millat/e-commerce-orders

Python Software Foundation. (2026). pandas: *Powerful* Python data analysis toolkit (versión 2.2) [Software]. https://pandas.pydata.org